### \* Regras de derivação

-	$(\arctan(u))' = \frac{u}{1+u^2}$
(u+v)'=u'+v'	$(\sec u)' = \sec(u) \tan(u) u'$
(u v)' = u' v + u v'	$(\arcsin(u))' = \frac{u'}{\sqrt{1-u^2}}$
$\left(\frac{u}{v}\right)' = \frac{u'  v - u  v'}{v^2}$	$(e^u)'=u'e^u$
$(u^n)' = n u^{n-1} u'  (n \in \mathbb{R})$	$(a^u)' = u' \ a^u \ln a \ (a \in \mathbb{R}^+ \setminus \{1\})$
$(\operatorname{sen} u)' = u' \cos u$	$(\ln u)' = \frac{u'}{u}$
$(\cos u)' = -u' \sin u$	$(\log_a u)' = \frac{u'}{u \ln a}  (a \in \mathbb{R}^+ \setminus \{1\})$
$(\operatorname{tg} u)' = \frac{u'}{\cos^2 u} = \sec^2 \left( e^{-\frac{u'}{2}} \right)$	$u'u' = h = f \circ g \mid h'(a) = f'(g(a)) \times g'$

# **\* Primitivas** $\int \sin^2 x \, dx = \frac{1}{2}x - \frac{\sin 2x}{4} \int \cos^2 x \, dx = \frac{1}{2}x + \frac{\sin 2x}{4}$

f(x)	$\int f(x) dx$	f(x)	$\int f(x) dx$
k	$kx + C$ , $k \in \mathbb{R}$	$\sin(u)u'$	$-\cos(u) + C$
$u^nu'$	$\frac{u^{n+1}}{n+1} + C$ , $n \in \mathbb{R} \setminus \{-1\}$	$\cos(u)u'$	$\sin(u) + C$
$\frac{u'}{u}$	$\ln  u  + C$	$\tan (u) u'$	$-\ln  \cos (u)  + C$
$e^uu'$	$e^u + C$	$\cot(u)u'$	$\ln  \sin (u)  + C$
$a^uu'$	$\frac{a^u}{\ln(a)} + C$ , $a \in \mathbb{R}^+ \setminus \{1\}$	$\sec^2(u) u'$	tan(u) + C
$\frac{u'}{1+u^2}$	arctan(u) + C	$\csc^2(u) u'$	$-\cot(u) + C$
$\frac{u'}{\sqrt{1-v^2}}$	$\arcsin(u) + C$	sec(u)u'	$\ln  \sec (u) + \tan (u)  + C$

## Parâmetros de Variáveis Aleatórias

Valor Esperado de X	$[\mu_X) E[X] = \mu_X = \sum_{i=1}^n x_i f(x_i)$
Variância de $X(\sigma_X^2) \rightarrow$	Desvio Padrão de $X(\sigma_X)$

$$E[X] = \int_{-\infty}^{+\infty} x f(x) dx$$
  
 $\times (\sigma_X)$   $Var[X] = \int_{-\infty}^{+\infty} (x - \mu)^2 f(x) dx$ 

# DISCRETAS (Suporte Finito ou Infinito Numerável)

- Função (Massa) de Probabilidade  $\rightarrow f(x) = P[X = x]$
- $\diamond$  Função de Distribuição (de Probabilidade)  $\rightarrow F(x) = P[X \le x] = \sum f(x_k)$
- 1. Distribuição Binomial  $X \sim Bi(n, p)$  (N° de sucessos em n provas de Bern)  $f(x) = \binom{n}{n} p^x (1-p)^{n-x}, \quad x = 0, 1, ..., n$   $E[X] = np \quad Var[X] = np(1-p)$

### 2. Distribuição Bernoulli (Binomial de n = 1) $X \sim Bern(p)$ (Moeda)

Provas de Bern A - Sucesso (p) Ā - Insucesso (1 - p)

$$f(x) = p^x (1-p)^{1-x}$$
,  $x = 0, 1$   $E[X] = p$   $Var[X] = p(1-p)$ 

3. Distribuição **Bin Neg**  $X \sim BinNeg(k, p)$  (N° de PdeB a realizar até obter k suce.)

$$f(x) = {x-1 \choose k-1} p^k (1-p)^{x-k}, \quad x = k, k+1, \dots \qquad E[X] = \frac{k}{p} \qquad Var[X] = \frac{k(1-p)}{p^2}$$

Quando k = 1, temos a Distribuição **Geométrica** - nº de PdeB até realizar o 1º sucesso

- **4.** Distribuição de **Poisson**  $X \sim Po(\lambda)$  (Contagem em Intervalos de Natureza Contínua)  $f(x) = \frac{e^{-\lambda} \lambda^x}{x}$ , x = 0,1,2,...  $E[X] = Var[X] = \lambda$
- **5.** Distribuição **Uniforme**  $X \sim U(n)$  (Todos os valores são equiprováveis)  $f(x) = \frac{1}{n}$

## CONTÍNUAS (Suporte Contínuo)

- $\Diamond$  **Função de Densidade** de Probabilidade f(x) **p.d.f.** Probabilidade de x assumir um valor específico
- ♦ Função de Distribuição Comulativa
  F(x)
  C.d.f. Probabilidade Acumulada de x ser ≤ a um valor esp
- $f(x) \ge 0$   $\int_{-\infty}^{+\infty} f(x) dx = 1$   $F(x) = P[X \le x] = \int_{-\infty}^{x} f(x) dx$
- 1. Distribuição Uniforme  $X \sim U(a, b)$   $E[X] = \frac{a+b}{2}$   $Var[X] = \frac{(b-a)^2}{2}$

 $f(x) = \frac{1}{a}$ ,  $a \le x \le b$  (é constante entre  $a \in b$ ); e 0 c.c.

- $F(x) = \frac{x-a}{b-a} \ , \ a \leq x \leq b \ ; \ 0 \ \text{em} \ x < a \ ; \ e \ 1 \ \text{em} \ x > b$
- **2.** Distribuição **Normal**  $X \sim N(\mu, \sigma)$   $f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$
- $Z = \frac{x-\mu}{\epsilon} \sim N(0,1)$ . (z-ecore) TAN  $(X \pm Y) \sim N(\mu_X \pm \mu_Y, \sqrt{\sigma_X^2 + \sigma_Y^2})$  $\bar{X} = \frac{\sum_{i=1}^{n} X_i}{n} \sim N\left(\mu_{\bar{X}} = \mu, \sigma_{\bar{X}} = \frac{\sigma}{\sqrt{n}}\right)$
- **3.** Distribuição **Exponencial**  $X \sim Exp\left(\frac{1}{2}\right)$
- $f(x) = \lambda e^{-\lambda x} \circ F(x) = 1 e^{-\lambda x} , x \ge 0 \qquad \lambda \circ \text{ a média da distribuição } E[X] = \frac{1}{4} \quad Var[X] = \frac{1}{\nu}$

Intervalos de Confiança

# Preparar o espoço
conf-c-0.95
a nível de confianç
cauda:-1-conf # peso dos coudos  $]I_{0.95}[_{\mu} = \bar{X} \pm erro = \bar{X} \pm \frac{1.96}{5} \sigma]$ 

Propriedades Valor Esperado E[X]

Var(k) = 0 Var(X + k) = Var(X)  $Var(X + k) = k^2 Var(X)$   $Var(X + Y) = Var(X) + Var(Y) \pm 2Cov(X, Y)$  Cov(aX, bY) = ab Cov(X, Y)

ullet Se X é uma v.a. de média  $\mu$  e variância  $\sigma^2$ Então a v.a.  $W = \frac{(x-\mu)}{2}$  tem E[W] = 0 e Var(W) = 1

 $Var[X] = E[(X - E[X])^2] = E[(X - \mu_X)^2]$ =  $E[X^2] - (E[X])^2 = \sigma^2$ 

Propriedades da Var(X)

# Simulação em CD

### Tipos de Simulação | Estocástica vs. Determinística

- ▶ Um modelo é determinístico se seu comportamento for totalmente previsíve Dado um conjunto de inputs, o modelo resultará num conjunto único de outputs
- > Um modelo é estocástico se tiver variáveis aleatórias como input e outputs

### Tipos de Simulação | Estática vs. Dinâmica

- Os modelos estáticos representam o sistema num determinado momento | MC
- ▶ Os modelos dinâmicos representam os sistemas à medida que evoluem ao longo do tempo.

### Simulação (Dinâmica) Discreta vs Contínua

- ▶ Na Simulação Discreta, as var. mudam <u>apenas num c</u>onjunto <u>discreto de pontos no tempo</u>
  - oas na fila da loja de croissants é um exemplo de simulação discreta. O nº de clientes muda apenas quando um novo cliente chega ou quando um cliente é atendido.
- ▶ Na Simulação Contínua, as variáveis de interesse mudam continuamente ao longo do tempo. Ex: Viagem de carro foi criado onde o interesse está na velocidade do carro ao longo da viagem.

# 2. Geração de NPA

- **NAs**  $\rightarrow$  [1° Req.] Ser capazes de **simular de forma independente** n°s aleatórios  $u_1, ..., u_N$  de U(0,1). [2º Requisito] Os números u1, u2, ..., uN necessitam de respeitar a independência
  - Devem ser realizações de **v.a., iid** e devem ser **não preditíveis**, i.e., não se deve consequir prever o próximo

Uma forma usual de testar NPA é aplicar testes estatísticos de **Uniformidade** 

2. Teste de hipóteses - Teste de Kolmogorov-Smirnov

- NPAs → São sempre de tipo determinístico e com output aparentemente aleatório
  - Devem ser: Rápidos de gerar | Ciclos de nº longos | Reprodutibilidade set.seed(n)
  - Os nºs aleatórios devem ser independentes e uniformemente distribuídos

### Qualidade dos NPAs

- \* Periodicidade
- \* Independência

  - Teste à autocorrelação de Rev.Plazos com representação gráfica da autocorrelação
- Os NPAs gerados pelos métodos seguintes são não correlacionados, ou seja, independentes. Apenas nos MCMC serão correlacionados.

### Método Congruencial Linear de Lehmer (GNPA Uniformes)

- $\otimes$  O algoritmo de Lehmer gera a seguência de inteiros  $X_* \in 0.1.\dots, m-1$  através de  $X_* \neg (aX_{m-1} + c) \mod$ m, onde mod m (módulo m) é o resto da divisão inteira por m. [5mod2 = 1 e 4mod2 = 0].
- ♦ Gera-se inteiros entre 0 e m 1. ♦ N° aleatórios entre 0 e 1 podem ser obtidos através de  $u_n = \frac{x_n}{n}$ .

- Input: m > 1 (módulo).  $a \in \{1, 2, ..., m-1\}$  (constante multiplicativa) 3. output  $X_n$  $c \in \{0, 1, \dots, m-1\}$  (incremento)  $X_n \in 0.1, \dots, m-1$  (semente)
- Output:  $X_1, X_2, X_3$  ... uma sequência de NPA
- 1. for n = 1, 2, 3, ... do 2.  $X_n$  ∈  $(aX_{n-1} + c)$  mod m
- Obs.: a expressão x congruente (y) módulo (m) significa que x é o resto da divisão inteira de y por m No caso específico deste gerador,  $X_n$  congruente a  $(aX_{n-1}+c)$  modulo m significa que  $X_n$  é o resto da divisão inteira de  $(aX_n-b,b)$  ocum
- ♦ O output depende de 4 parâmetros: m (módulo), a (const. multiplicativa), c (incremento), X₀ (semente);
- ◆ Caso sejam escolhidos convenientemente a sequência resultante comporta-se de forma semelhante ao de uma sucessão de v.a. iid uniformes
- Dado que X<sub>n</sub> pode assumir apenas m valores distintos o output de um gerador congruencial começa a repetir-se depois de m passos, no máximo - é **periódico**. Para ultrapassar isso,  $m=2^{32}$  ou  $m=2^{64}$ .
- Ex.: [1] 0.0625 0.8125 0.5625 0.3125 0.0625 0.8125 0.5625 0.3125  $m = 64, a = 13, c = 0, X_0 = 4$ Comprimento do Ciclo = Período = 4 → Não escolhia este α e c porque resulta num ciclo curto

### Método da Transformação Inversa $F(X)^{-1}$ (GNPA Não Uniformes)

- @ Gera v.a. usando como input os valores NPAs uniformes em [0,1].
- $\odot$  Transforma os NPAs de uma U(0,1) noutra distribuição, tirando vantagem do facto da inversa da função Inverter uma Função

## distribuição ser tmb definida no intervalo [0.1].

- Input:  $F^{-1}$  (Inversa de F)

  1.  $X = F^{-1}(U)$
- Output:  $X \sim F$ O Aplicado para gerar observações de v.a. contínuas.
- Mas não pode ser usado diretamente para normais.

discretas. Só após uma adaptação simples.

- Não pode ser usado diretamente para simular v.a.
- 1 e<sup>-kx</sup> = v em ordem a v Ou seia:  $-\lambda x = log(1 - u)$
- $\mathbf{R}$ : Pode-se aplicar sempre que F(x) tem função analítica **conhecida** e **invertível**. No caso de ser uma dist. contínua pode-se aplicar diretamente, mas no caso de ser uma dist. discreta tem de ser mediante artifícios (não é diretamente e é em apenas alguns casos).

### Método da Aceitação/Rejeição

- ⚠ É baseado na função densidade de probabilidade (pdf), em vez da função distribuição. Logo, se a pdf de X for conhecida, f(x), então é possível gerar NPA de X pelo **método da aceitação-rejeição**.
- A Método que gera amostras de uma distribuição de interesse, f(x) , a partir da geração de candidatos de uma distribuição conhecida, g(x), e rejeitando um subconjunto dos candidatos gerados
- ▲ O que se deve garantir é que a curva de g tem que estar sempre "acima" da curva de f. Daí, multiplicamos a por uma constante, c, de forma a garantir que,  $c \times a(x) > f(x)$
- Logo, em média, cada valor amostral de X necessita de c iterações
- $\text{$\mathbb{A}$ Aceitamos $x$ com probabilidade } \frac{f(x)}{\epsilon \, x g(x)} \quad \text{Note-se que o quociente varia entre $0$ e $1$} \\ (\epsilon * g(x) \stackrel{\text{$\alpha$}}{\epsilon} \text{ sempre maior ou igual a } f(x)), o que permite que este que o probabilidade }$ f(x) grande - nº muito provável na distribuição alvo ou de interesse
- Se  $\frac{f(x)}{c \times g(x)}$  for **grande**: g(x) pequeno n° pouco provável na distribuição de candidatos
- Aceita-se esse número porque podemos não ter novamente proposta de um número tão raro (a sua P de ocorrência é baixa na dist. de candidatos) e ele tem P elevada na distribuição alvo
- Se  $\frac{f(s)}{c \times g(s)}$  for **pequeno**: f(s) pequeno nº pouco provável na distribuição alvo ou de in g(s) grande nº muito provável na distribuição de candidatos
- Reieita-se esse número porque este tem grande probabilidade de aparecer como candidato, mas não é comum (ou seja, tem probabilidade, P, baixa) na distribuição alvo.

- ullet O n $^{\circ}$  de gerações de g(x) necessários para obter um valor gerado f(x) tem  ${f dist.}$   ${f Geométrica}$  com
- c é designada por Constante de Rejeição; convém então escolher c através de  $c = \sup_{x \in C} f(x)/g(x)$
- Prob. Total de Aceitação p/ qualquer iteração =  $\sum_{x} P(\text{aceitar} \mid x) * P(X = x) = \sum_{x} \frac{f(x)}{g(x)} * g(x) = \frac{1}{2}$

### Outras Transformações

♦ Pretende-se gerar NPAs de uma dist., com base numa relação existente com outra dist. conhecida.

### Transformações Importantes

- **1.** Se  $Y \sim N(\mu, \sigma)$ , usando a transformação  $X = e^Y$ , X tem distribuição  $\log N(\mu, \sigma)$ , pois  $\log X = Y$
- **2.** Se  $Z \sim N(0,1)$ , então  $V = Z^2 \sim \gamma^2(1)$ .
- 3. Se  $U \sim \chi^2(m)$  e  $V \sim \chi^2(n)$  são indp., então  $F = \frac{u_{/m}}{v_{/m}}$  tem dist. From (m,n) graus de liberdade.
- **4.** Se  $Z \sim N(0,1)$  e  $V \sim \chi^2(n)$  são indp., então  $T = \frac{Z}{\sqrt{N/n}}$  tem **dist.** t de Student com n gdl.
- 5. Se  $U, V \sim U(0,1)$  são indp., então  $z_1 = \sqrt{-2\log U} \cos(2\pi V)$  e  $z_2 = \sqrt{-2\log U} \sin(2\pi V)$  são 2 v.a. indp.  $\sim N(0,1)$ .
- **6.** Se  $U \sim Gama(r, \lambda)$  e  $V \sim Gama(s, \lambda)$  são indp., então X = U/(U + V) tem **dist.** Beta(r, s).
- 7. Se  $U, V \sim U(0,1)$  são indp., então  $X = \lfloor 1 + \log(V) / \log(1 (1-q)^U) \rfloor$  tem **dist.** Logaritmica(q),
- 8.  $U \sim U(0,1)$ , então  $X = -(1/\lambda) log U$  terá distribuição  $Exp(\lambda)$ .

## Somas/Convoluções e Misturas | Tipos Especiais de Transformações.

### Somas Importantes

- **1.** Se  $Z_1, ..., Z_n \sim N(0,1)$ , então  $V = \sum_{i=1}^n Z_i^2 \sim \chi^2(n)$
- 2. A dist. binomial negativa BinNeg(r,p) pode ser definida como a convolução de r va iid Geom(p).
- **3.** A soma de r v.a.  $Exp(\lambda)$  indp. tem dist.  $Gama(r,\lambda) \rightarrow A$  soma de grau r da  $Exp(\lambda)$  é uma  $Gama(r,\lambda)$ .
- 4. A soma de n va iid Ber(p) tem dist. Bin(n,p).
- + A soma de  $X_1 \sim Pois(\lambda_1)$  e  $X_2 \sim Pois(\lambda_2)$  dá  $X \sim Pois(\lambda_1 + \lambda_2)$
- ullet Uma v.a. X  $\acute{ ext{e}}$  uma **mistura discreta** se  $F_X(x) = \sum_{i=1}^k \theta_i F_i(x)$ ,  $\operatorname{com} \theta_i > 0$   $\operatorname{e} \sum_{i=1}^k \theta_i = 1$
- ullet E mistura contínua se  $F_X(x)=\int_{-\infty}^{+\infty}F_{X|Y=y}(x)f_Y(y)dy$ , com  $f_y>0$  e  $\int_{-\infty}^{+\infty}f_Y(y)dy=1$

# 3. Método de Monte Carlo em Inferência Estatística

### Estimação Pontual | Propriedades dos Estimadores

- Seia T. estimador para θ.
- T diz-se eficiente se, entre todos os estimadores não enviesados para  $\theta$ , for o que apresenta min(Var)
- ullet T diz-se suficiente se utiliza toda a informação disponível na amostra, relevante para a estimação de ullet.
- EP | Propriedades Assintóticas dos Estimadores
  - ♦ T diz-se não enviesado <u>assintoticamente</u> (ou **assintoticamente centrado**) se  $\lim E[T_n] = \theta$
  - $\lim_{n\to\infty} E(T_n-\theta)^2]=0 \Leftrightarrow \lim_{n\to\infty} E(T_n-\theta)^2]=0 \Leftrightarrow \lim_{n\to\infty} E(T_n-\theta)^2]=0 \Leftrightarrow \lim_{n\to\infty} E(T_n-\theta)^2=0 \Leftrightarrow \lim_{n\to\infty} E(T_n-\theta)^$
  - ♦ T diz-se <u>assintoticamente mais</u> eficiente se for aquele que apresenta Var mínima, de entre todos os consistentes em média quadrática
  - SMC ( = MC Paramétrico necessita de um modelo gera amostras da f.d.p. da dist. da pop. ) Usa amostragem repetida para obter as propriedades estatísticas de algum fenómeno
  - Permite estimar a potencia de um teste de hipóteses.
  - ➣ Os métodos de Monte Carlo variam, mas tendem a seguir um padrão específico:

### Estimação do Erro Padrão

- ↑ O erro padrão de um estimador é o seu **desvio-padrão**. Sabemos que a distribuição de X<sup>-</sup> tem média  $\mu$  e variância  $\sigma^2/n$ . Então o erro padrão de X é  $SE(\overline{X}) = \sqrt{Var(\overline{X})} = \int_{n}^{\sigma^2} = \frac{\sigma}{\sqrt{n}}$
- Estimação do MSE Mean Squared Error =  $\frac{\sum (y_i \hat{y}_i)^2}{2}$ A Definir o valor esperado, y<sub>i</sub>, e calcular a média dos erros quadrados

- 4. MCMC (Método de MC via Cadeias de Markov)
- x Todos os **Métodos MCMC (M-H, P.A., A.I.,** ...) são baseados no **Método da Aceitação/Rejeição**
- imes Nos **Métodos MCMC** pode-se retirar uma **amostra de um número** m < n dos valores gerados para obter uma amostra independente.

### Cadeias de Markov

- I Diz-se aperiódica se todos os estados tiverem período 1
- X Constituem uma classe de algoritmos para simular distribuições multivariadas complexas « Baseiam-se na construção de uma CM homogénea que tem como dist. lim a que se pretende simular.
- I Um Processo de Markov (PM) é um sistema que possui estados, e que os alterna com uma dinâmica.
- I Todos os estados formam um **espaço de estados**, que geralmente, é finito (embora possa ser grande).
- I Uma sequência de estados chama-se cadela.

# 1. A propriedade de Markov afirma que a dinâmica futura do sistema de um qualquer estado depende

- apenas desse estado. → Cada estado é independente (Falta de Memória)
- 2. Estacionaridade: As probabilidades de transição entre estados não mudam com o tempo.  $T = N \times N$
- CM | É uma sequência de v.a. dependentes, onde a prob, condicional de  $X_r$  depende apenas de  $X_{r-1}$ .  $P(X_t = x_j | X_{t-1} = x_{it-1}, ..., X_2 = x_{i2}, X_1 = x_{i1}) = P(X_t = x_j | X_{t-1} = x_{it-1})$
- X Kernel de Transição/Markov (K) é a distribuição condicional de X<sub>t+1</sub> dado X<sub>t</sub> (é P condic A distribuição condicional de  $X_t|X_{t-1}$  é o **Kernel de transição** K e tem-se  $X_{t+1}|X_t, X_{t-1}, \dots, X_2, X_1, X_0 \sim K(X_{t+1}|X_t)$
- X Distribuição Estacionária: Geralmente têm uma distribuição estacionária Se  $X_t \sim f$  então  $X_t + 1 \sim f$  tendo-se  $\int \chi K(y \mid x) f(x) dx = f(y)$
- Irredutibilidade: significa que o kernel permite movimentos em todo o espaço de estados ara qualquer X<sub>a</sub>, a sucessão (X<sub>e</sub>) tem uma P positiva de visitar qualquer região do espaço de estas
- X Recorrência: implica que elas retornam infinitas vezes a qualquer estado.
- X Ergodicidade: A distribuição estacionária é também uma distribuição limite, e a cadeia converge para o valor esperado, independentemente do valor inicial.
  - Se f é a distribuição de probabilidade limite então  $X_r \rightarrow X \sim f$  , para qualquer valor inicial  $X_n$
- X Para funções integráveis h, e desde que exista o valor médio E[h(X)],  $\frac{1}{T}\sum_{t=1}^{T} h(X_t) \xrightarrow{p} E[h(X)], \text{ quando } T \to \infty$
- Lei dos Grandes Números (por vezes chamado Teorema Ergódico)

- X Da existência de um processo estacionário sabe-se que, independentemente do valor inicial,  $x_0$ , uma amostra da distribuição estacionária é gerada, desde que o período seja longo o suficiente
- X Fase de burn-in (fase de aquecimento) o MCMC precisa de um certo tempo para produzir valores de uma dist. estacionária
- X Cada "região" pode ser alcancada com P + para a região definida.
- X Enquanto uma cadeia for recorrente, o MCMC converge

# Simular essa cadeia por um longo período de tempo, até que ela convirja (aproximadamen A cadeia vai gerar a amostra da sua distribuição estacionária, que á a distribuição alvo f.

## Vantagens

- As cadelas de Markov possuem diferentes propriedades de convergência, que podem ser exploradas para se obter dist, proj
- O conhecimento necessário da distribuição alvo f de onde se quer gerar os números é mínimo Estes métodos facilitam a resolução de problemas de alta dimensão (contrariamente ao método de Aceitação-Rejeição), através de uma

- **Algoritmo** Metropolis-Hastings El Gera variáveis correlacionadas a partir de uma CM. Note-se que até agora, temos gerado variáveis lid
- $\mathbb{E}$  Existe um valor candidato Y. gerado a partir de uma dist. candidata  $g(y|X_r)$  e se este valor candidato:
- $\odot$  **6 aceite**, a cadeia move-se para o estado Y no tempo t+1 e  $X_{t+1}=Y_t$ não é aceite, a cadeia permanece no estado X<sub>t</sub> e X<sub>t+1</sub> = X<sub>t</sub>. Logo, repete valores!
- ☐ As condições exigidas para a cadeia gerada são: ocorra em mais de 1 etapa) de qualquer estado para qualquer outro estado
- Irredutibilidade: uma P ≠ 0 de transição (mesmo que ocorra em mais de 1 ets Recorrência positiva: se o tempo esperado até o retorno for finito Aperiodicidade: não deve haver estados absorventes (estados em que uma
- O algoritmo GERAL de M-H gera uma cadeia de Markov X<sub>0</sub>, X<sub>1</sub>, ... de acordo com:
- Defina uma distribuição candidata a( IX.) (Tem de ter domínio/suporte = ao de  $f \rightarrow B$  two etc of effetors
- 2 Define um valor inicial V. dentro do domínio de a
- Gere um valor **candidato**  $Y = X_{t+1}$  a partir de  $g(\cdot \mid X_t)$ (note que o valor candidato é dependente do valor ante • Gere U de uma U(0,1) • Calcule a probabilidade de aceitação de M-H

CP | Passeio Aleatório

- · · <sub>ℓ+1</sub> = X<sub>ℓ</sub>
   Nota: O algoritmo foi desenvolvido de fi é a dist. alvo f

 $\alpha(X_t, Y) = min\left(\frac{f(Y) \times g(X_t \mid Y)}{f(X_t) \times g(Y \mid X_t)}, 1\right)$ 

- imes Num passeio aleatório verifica-se  $X_{t+1} = X_t + \varepsilon_t$  com  $\varepsilon_t \sim N(0,\sigma)$ . Se os ε, são independentes então X, é independente de X, X, X, X, mas condicional a X,
- O Num PA, em cada etapa, qualquer movimento para a frente tem probabilidade a de ocorrer e qualquer movimento para trás ten
- 9 Um movimento ocorrido do estado é para o é + 1 depende apenas do estado é. Logo, um passeio aleatório é uma Cadeia de Marko.

```
\emptyset Se g(\cdot|X_t) é simétrica, então g(X_t|Y) = g(Y|X_t), e a P(\text{aceitação}) é dada por \alpha(X_t,Y) = min\left(\frac{f(Y)}{f(Y_t)},1\right)
```

👑 Se um valor candidato Y = X..., é gerado a partir de uma dist. candidata simétrica, então a probabilidade da cadeia se mover de  $X_s$  para  $X_{ss}$ , depende apenas da distância entre eles:  $g(X_{ss}, |X_s) = g(|X_{ss}, -X_s|)$ . Logo, a cada iteração, um incremento Z é gerado a partir de  $g(\cdot)$ , e Y é definido como $Y = X_t + Z$  (**definição de random walk**)

 $\bullet$  O incremento aleatório Z pode ser  $N(0, \sigma)$ , de forma que o  $Y|X_t \sim N(X_t, \sigma)$ , para algum  $\sigma > 0$  constante Mas o incremento Z também pode ser  $U(-\delta, \delta)$ , por exemplo.

• Defina uma dist. proposta g simétrica Defina X<sub>a</sub>, dentro do domínio de f · Repita os sequintes passos até convergir  Gere U da U(0,1)
 Calcule a taxa de aceitação α(X<sub>t</sub>, Y) Se  $U \le \alpha(X_t, Y)$  aceite Y e faça  $X_{t+1} = Y$ ; Caso contrário faça  $X_{t+1} = X_t$ 

### **CP | Amostrador Independente**

 $\Rightarrow$  Neste método, a g(x) não depende de valores anteriores da cadeia, ou seja,  $g(Y|X_t) = g(Y)$ .

 $\begin{tabular}{l} \clubsuit \text{ A probabilidade de aceitação \'e} & \alpha(X_t,Y) = min\left(\frac{f(Y)}{f(X_t)}/\frac{g(Y)}{g(X_t)},1\right) = min\left(\frac{f(Y)g(X_t)}{f(X_t)g(Y)},1\right) \end{tabular}$ 

Nota: Embora os valores de  $Y=X_{t+1}$  sejam gerados de forma independente, <u>a cadela resultante não será iid</u>, já que a probabilidade de aceitação ainda depende de  $X_t$ .

- Defina uma dist. candidata g similar à f
- Defina  $X_{nr}$  dentro do domínio de g
- Repita os seguintes passos até convergir
- Gere um valor candidato Y a partir de g 2. Gere *U* de uma *U*(0,1)
- 3 Calcule a tava de aceitação a(Xt V) Se  $U \le \alpha(X_t, Y)$  aceite Y e faça  $X_{t+1} = Y$ ; Caso contrário faça  $X_{t+1} = X_t$

# 5. Métodos de Reamostragem

```
Bootstrap (MC Não Paramétrico porque não precisa de saber nenhum modelo, apenas usa a amostra original c/ reposição )
```

Uma amostra **bootstrap** é um conjunto de valores extraídos aleat, **com reposição** da amostra original L A estimativa de  $\theta$  na b —ésima reamostra bootstrap é  $\theta^{(b)}$  A EP Bootstrap é o Estimativa Bootstrap do viér

 $F_{n}(x)$  é um estimador de  $F_{v}(x)$  para todo o x

 $\overrightarrow{\text{vios}}^*(\hat{\theta}) = \overline{\hat{\theta}^*} - \hat{\theta}$  $\overrightarrow{\widehat{\theta}} = \frac{1}{B} \sum_{k=1}^{B} \widehat{\theta^{(k)}} \qquad \text{com } \widehat{\theta}^* = \stackrel{\circ}{\leftarrow} \quad \text{e} \\ \widehat{\theta} = \widehat{\theta}(x) = \widehat{\theta}(x_1, \dots, x_n)$ mean(rowMeans(S)) - mean(smpl)

Para cada estimativa de hootstran indevada h = 1 R:

- 1. Gere uma amostra  $x^{*(b)} = (x^*, ..., x_n^*)$ , através de amostragem com reposição de amostra
- **2.** Calcule a b –ésima estimativa  $\hat{\theta}^{(b)}$  da b –ésima amostra de bootstrap  $x^{*(b)}$

### Cross-Validation

Conjunto de Validação

 $\blacksquare$  Leave-One-Out (LOOCV k = n) 

CV método é simples e fácil de implementar. No entanto o MSE de validação pode se Itamente variável e. apenas um subconiunto de obs. é usado para aiustar o model (dados de treino), sendo estas duas grandes desvantagens deste método

LOOCV em comparação com a abordagem do CV tem menos enviesamento e o MSE é menos variável. Contudo, é computacionalmente intensivo (desvantagem). K-fold é o melhor método dado que computacionalmente não é tão intensivo

O erro de teste pode ser facilmente calculado aplicando o método às observações usadas no seu traino.

# **6.** Simulação de Eventos Discretos

# Elementos de um Modelo de Simulação

### 1 | Obietos do Modelo

Entidades: elementos individuais do sistema que estão sendo simulados e cujo comportamento está sendo explicitamente rastreado. Cada entidade pode ser identificada individualmente;

Recursos: também elementos individuais do sistema, mas não são modelados individualmente, mas tratados como itens contáveis cuio comportamento não é rastreado.

Os funcionários podem ser considerados entidades ou recursos:

No 1º caso, nodemos rastrear o tempo total de trabalho de cada um deles: no 2º caso, o modelo só seria canaz de produzir uma visão

### 2 | Organização de Entidades e Recursos

Atributos: propriedades de entidades e recursos. Geralmente é usado para controlar o com

x: Estado de um funcionário (ocupado ou disponível).

Estado: conjunto de var. necessárias para descrever o sistema em qualquer momento. Es. No caro mair rimpler, ar varifueir rão o púmero do clienter na fila o o púmero do funcionários ocupados

Lista: coleção de entidades ou recursos ordenados de alguma forma lógica.

### 3 | Operações dos Objetos

Durante um estudo de simulação, entidades e recursos irão cooperar e, portanto, mudar de estado Evento: instante de tempo em que o estado do sistema muda.

Ev. Quando um cliente termina de con standido: o nº de funcionários ocupados diminui em um e há um cliente a menor na fil-

Atividade: um período de tempo de duração especificada do qual se conhece o início (embora a sua duração possa ser aleatória). Fir: O tempo que um funcionário leva a atender 1 cliente: isso pode ser especificado em termos de uma distribuição al

Delay, duração de tempo não especificada, que não é conhecida até o término. não é especificado pelo modelador com antecedência, mas é determinado pelas condições do sistema. Muitas vezes, este é um dos resultados desejados de uma simulação

Ex: Tempo de espera de um cliente na fila de nossa loia de croissants

```
Clock: variável que representa o tempo simulado
```

```
# ==== (Re)Amostragem Aleatória Simples ==== # ==== Geradores de Dist. Do R =====
samnle(x.
                                                            rxx(n, *) - Gerar n NPAs
matrix(rx(n*m), nrow=n, ncol=m) - Gerar n x m NPAs
                 - Vetor de onde escolher os números discretos
        Size, - Nº de elementos a amostrar;
Se não for especificado é igual à dimensão x
(Permutação aleatória dos elementos)
                                                            \begin{array}{ll} dxx(x, \ ^{*}) & - \text{Função Densidade num certo } x \\ pxx(p, \ ^{*}) & - \text{Função de Distribuição } F(x) = P[X \leq x] \\ qxx(q, \ ^{*}) & - \text{Função Quantil (Inversa da fd)} \end{array} 
        replace = T/F, -Com/Sem Reposição
prob = C()) - Probabilidade dos eler
       prob = c())
                              ======== Oualidade dos NPAs ===
  Histograma
                                                  # Teste de Kolmogorov-Smirnov (de giustamento)
ks.test
hist(u, prob = TRUE)
                                                 ks.test(u, "punif") # Se p-value < 0.05 -> Não rejei
a H0 de que a seq. tem dist. U.
# f.d.p. da U(0.1)
abline(h=1, col="red")
text(0.85,.95, "fdp U(0,1)", col="red");
                    O OO-plot representa a sequência x para verificar se os dados podem seguir uma dist
# Gráfico QQ
                       Se os pontos não diferem muito da linha reta e, neste caso, podemos assumir que os dados são de uma certa dist. (p.e. U(0.1)).
n <- 1000
x <- runif(n)
q <- qunif(ppoints(n)) # ppoints gera uma sequência de pontos de probabilidade
gaplot(a, x,
        cex=0.25,
xlab="U(0,1)"
                           # cex diminui o tamanho dos pontos para 25%
         vlah="cample"
abline(0, 1, col = 2)
# Teste à Independência - Teste de Box-Pierce ou Lags
acf(u) # Estima a função de autocorrelação e elabora por defeito o gráfico da função
                           ----- Gerador Congruencial Linear
alcm <- function(N, x0, a, c, m){
                                                        # Renlica os elementos do vetor entre 0 e N
   x <- rep(0,N)
        (i in 2:N) x[i] <- (a*x[i-1]+c)%%m # %% implementa o módulo (mod)
    return(x)
                                                 # Se quisermos que os NPAs \sim U(0,1) então (x/m)
                                ==== Método da Transformação Inversa =====
# Gerar 1000 valores do modelo f(x) = 3x^2 , x \in [0,1]
u (- runif(n)
hist(x, prob = TRUE, main = bquote(f(x)==3*x^2)) # bquote - incluir a expressão da função no título
curve(3*x^2,0,1, add=T ,col="red")
# Obter 5 observações de uma v.a. Exponencial com o parâmetro \lambda=2.
invF <- function(u,lambda) -log(1-u)/lambda
```

invF(u, lambda = 2) # Gerar pela inversa 20 valores do modelo Bernoulli com p=0.4p <- 0.4; n <- 20;  $x \leftarrow as.integer(u > 0.6)$  # Se fizermos mean(x) e var(x) podemos comparar com a pop. ====== Método da Aceitação-Rejeição ====== foo <- function(x) fx(x)/gx(x)opt <- optimize(foo, c(0,4), maximum = TRUE)

c <- opt\$objective
paste("Valor Ótimo de c =", round(c,2)) # Nº Valores Aceites = n x c</pre> # Estabelece um contador para o número de observações aceites count = 0 # Estabelece um contador para o número de iterações percorridas accept = c()

# Percorrer o algoritmo até atingir os 10 000 NPAs gerados while(k < 10000){ # Gerar x da distribuição g(x) proposta - N(0,1)# Gerar um u da distribuição Uniforme(0,1) U\_sim <- runif(1, 0, 1) # Calcular o valor de  $f(x)/(c \times g(x))$ cg\_x <- fx(X)/(c\*dnorm(X)) # Comparar os dois valores - Aceita-se ou Rejeita-se if(U sim <= cg x){ # Se o valor de U(0,1) for inferior ou igual a cg(x), então: # Aceitar a simulação acrescentando uma linha ao vetor 'accept accept = rbind(accept, X)

# Caso contrário, descartar a simulação, aumentar o contador em 1, e

seguir para a próxima iteração

paste("Nº de Iterações".count) paste("Nº de Valores 'y' Aceites",length(accept))

count = count + 1

=== Simulação de Eventos Discretos [1] | Simmer == library(simmer)
env <- simmer("Croissant shop")</pre> # Cria um Ambiente de Simulação customer <- trajectory("Customer") %>% # Cria uma Trajetória (CLiente) log\_("Here I am") %>% seize("employee", 1) %>% # Bloqueia o recurso employee timeout(function() runif(1,1,5)) %>%
release("employee", 1) # Define a dist. da atividade do recurso add\_resource("employee", capacity = 2) %>% # Gera-se 2 funcionários # Gera-se a chegada dos clientes add\_generator("customer", customer, function() rexp(1,1/3) # dist. OU at(vetor de tempos) OU

mon = 2)# Se o simulador deve monitorar as chegadas geradas:
# 0 = sem monitoramento, 1 = monitoramento simples,
2 = nivel 1 + monitoramento de atributo de cheaada
# Executa a simulação por 2h

env %>% get mon arrivals(ongoing=TRUE) # Monitorização dos clientes (= T até os n atendidos %>% transform(waiting\_time = end\_time - start\_time - activity\_time)

env %>% get\_mon\_resources() # Estatísticas dos recursos ("resource", "time", "server", "
"capacity", "queue size", "system", "limit", "replication") env %>% get\_mon\_attributes() # Atributos ("time", "name", "key", "value", "replication")

```
## Usando a relação existente entre as distribuições uniforme continua e Logaritmica,
obtenha uma amostra aleatória de 1000 números com distribuição Logaritmica(0.5).
                                  theta <- 0.5:
   x \leftarrow floor(1 + log(v) / log(1 - (1 - theta)^u)) # floor dá a parte inteira de um número
  ## Calcula as probabilidades teóricas (exactas) usando a definição da distribuição
  p <- -1/log(1 - theta) * theta^k/k
  ## Comparação gráfica dos valores gerados com a prob. teórica
                                                                                                                            # Gráficos Lado a Lado
  par(mfrow = c(1, 2))
  lty = 1, col = c(1, 2))
                                                                       # Gráfico da Função de Distribuição Cumulativa Empírica
   plot(ecdf(x)) # Grafi
lines(cumsum(p), type = "s", col = 2)
   # ----- Somas --
Algorithm: \max_{j \in \mathcal{I}_{M}} Algorithm: \max_{j \in \mathcal{I}_{M}} \max_{j \in \mathcal{I}_{M}} \sum_{k \in \mathcal{I}_{M}} \sum_{j \in \mathcal{I}_{M}} \max_{j \in \mathcal{I}_{M}} \sum_{k \in \mathcal{I}_{M}} \sum_{j \in \mathcal{I}_{M}} \sum_{k \in \mathcal{I}_{M}} \sum_{j \in \mathcal{I}_{M}} \sum_{k \in \mathcal{I}_{M}} \sum_{j \in \mathcal{I}_{M}} \sum_{k \in \mathcal{I}_{M}} \sum_{k \in \mathcal{I}_{M}} \sum_{k \in \mathcal{I}_{M}} \sum_{j \in \mathcal{I}_{M}} \sum_{k \in \mathcal{I}_{M}}
   X <- matrix(rnorm(n*v), nrow=n, ncol=v)^2 # Matriz dos quadrados das N(0,1)
  Ex.: Seja X_1 - Gama(2, 2) e X_2 - Gama(2, 4) independentes.

Gerar 1800 NPAs pela convolucão S = X_1 + X_2 e pela mistura f(X) = 0.5f(X_1) + 0.5f(X_2).
            Algoritmo para Soma/Convulção: 
1. Gerar X_1 NPA Gama(2,2) 
2. Gerar X_2 NPA Gama(2,4) 
3. Obter S=X_1+X_2
            n <- 1000;
                                           x1 <- rgamma(n, 2, 2); x2 <- rgamma(n, 2, 4)
   u <- runif(n)
   k <- as.integer(u > 0.5) # Vetor de 0 e 1
    x <- k * x1 + (1-k) * x2 # Define a mistura
  par(mfcol=c(1,2))
hist(s, prob=TRUE, xlim=c(0,5), ylim=c(0,1), main = "Soma de Gammas")
hist(x, prob=TRUE, xlim=c(0,5), ylim=c(0,1), main = "Mistura de Gammas")
    Ex.: Gerar 1000 NPAs com dist. com distribuição Binomial(n = 6,p = 0.5) pela soma de distribuições de Bernoulli
   for (i in 1:1000) {
      soma <- sum(bern_sample)
    # Para confirmar os resultados mean()= E[X]=np=6	imes0.5=3 e var()=np(1-p)=1.5
  Ex.: Suponha que X_1 \sim N(0,1) e X_2 \sim N(3,1) e são independentes.
             Gere 1000 NPA da mistura f_X(X) = \frac{1}{3}f(X_1) + \frac{2}{3}f(X_2)
               Algoritmo:
              Para gerar NPA da mistura de duas normais é 
1. Gerar um inteiro k \in \{1,2\}, onde P(1)=1/3 e P(2)=2/3
                                                  Output: x NPA do modelo N(0,1)
Output: x NPA do modelo N(3,1)
  n <- 1000; mu<-c(0,3)
k <- sample(1:2, size=n, replace=TRUE, prob=c(1/3,2/3))
                                                    # vector dim=n (mu_k1,...,mu_kn), elementos mu[1]=0 ou mu[2]=3
  m <- mu[k]
   x <- rnorm(n, m, 1)
  100 amostras de dimensão n=20 | 100 amostras de dimensão n=100 | 100 com n=1000
                Obtenha, para cada amostra gerada e para cada estimador, a assimetria amostral (estimativa) corre
Recorrendo ao cálculo do erro-padrão e do erro quadrático médio, conclua pela sua preferência...
    # Gerar as Amostras - matriz n Linhas x 100 colunas
    sample_20 <- replicate(100, rt(20, df = 20))
   sample 100 <- replicate(100, rt(100, df = 20))
    sample_1000 <- replicate(100, rt(1000, df = 20))
    # Calcular s1 e s2 para cada amostra de 20 observações
   s1_values_20 <- apply(sample_20,
MARGIN = 2,
                                                                           # MARGIN = 2 | Aplicar função nas Colunas
                                                 FUN = s1 estimator) # FUN = função que queremos aplicar
    # Calcular Erro-Padrão e Erro Quadrático Médio para s1 e s2
  se s1_20 <- sd(s1_values_20) / sqrt(100) 
mse_s1_20 <- mean((s1_values_20 - 0)^2) # Neste caso Valor Esperado = 0 ...
                                      ===== Simulação de Eventos Discretos [2] | Simmer ==
    # Gráfico que representa os recursos
  plot(resources, metric = "usage",steps=1) 
 - A Linha verde = n^2 de recursos ocupados (p.e., funcionários); 
 - A Linha vermelha = n^2 de pessoos no fila que estão à espera para serem atendidas.

    A Linha azul

                                            = nº total de clientes no sistema: fila + os que estão a ser o
  [FXTRA]
  # Clientes Prioritários (Só depois dos outros serem atendidos)
     ... add_generator(.env, name_prefix, trajectory, distribution, mon, priority = 1)
   # Clientes Prioritários com urgência (Com atendimento primeiro)
  env %>%
     ... add_resource(name, preemptive = TRUE) %>%
       ... add_generator(_, priority = 1)
```

# Desistência do Serviço pelos Clientes

customer <- trajectory("Customer") %>%
 ... seize("counter", continue = FALSE, reject = trajectory("Balked customer")) %>%

# Nº Clientes que Desistiram sum(get\_mon\_arrivals(env)\$activity\_time == 0)

... add resource("counter", queue size = 1) %>% ... # queue size = capacidade da fila

# Taxa Horária de Desistência sum(get\_mon\_arrivals(env)\$activity\_time == 0)/now(env)\*60

=== Métodos de Transformação ====:

```
f \leftarrow function(x, sigma) \{(x / sigma^2) * exp(-x^2 / (2*sigma^2)) #x>0, sigma>0\}
 x[1] <- rchisq(1, df=1) # Valor înicial X<sub>0</sub> - Não é um valor inteiro e pode não o ser
k <- 0 # Regista o número de rejeições
u <- runif(T) # Gera os T valores NPA U(0,1)
for (i in 2:T) {
  xt <- x[i-1]
y <- rchisq(1, df = xt)
                                                                        # Valor candidato - a(r)
   num <- f(y, sigma) * dchisq(xt, df = y);
den <- f(xt, sigma) * dchisq(y, df = xt);
    alpha <- min(num/den.1)
   if (u[i] <= alpha) {x[i] <- y}
else {x[i] <- xt;
                                                                          # 0 X, é o x[i-1] = Valor Anterio
             k <- k+1}
                                                                         # Incrementa k porque y foi rejeitado
 ## Comparação da dist. teórica e empírica | fdp da Rayleigh sobreposta ao histograma das obs. geradas,
deitando fora as primeiras 2000 observações da cadeia de Markov (burn în sample). Com os quantis mostrats e os quantis teóricos. b < 2001 # burn în sample fora; y <- x[b:T]; a <- ppoints(100) QR <- sigma * sqrt(-2 * log(1 - a)) # quantis da Rayleigh
 par(mfrow=c(1,2))
 qqplot(QR, y, main="", xlab="Quantis Rayleigh", ylab="Quantis Amostrais")
 abline(0, 1,col="red")
hist(y, main="", xlab="", freq=FALSE)
 lines(OR, f(OR, 4))
                          ====== MCMC M-H | Passeio Aleatório ======
Gerar valores de uma normal padrão, usando como distribuição candidata a U(-0.5,0.5). f <-function(x) dnorm(x, 0, 1); delta <- 0.5; N <- 500; x <- numeric(N);
 x[1] <- runif(1, -delta, delta)
for(i in 2:N) {
      u <- runif(1)
       if(u <= alpha) {x[i] <- y}
       else {x[i] <- x[i - 1]}
 plot(x, type = "l")
 # Comparar a dist. das amostras com a dist. teórica.
 par(mfrow = c(1, 2))
 plot(ecdf(x), main = expression(delta == 0.5))
 curve(pnorm(x), add = TRUE, col = 2)
                       ====== MCMC M-H | Amostrador Independente ===
 Gere 500 NPA de uma distribuição Beta(2,3) usando como candidata a N(0.5, 0.25)
f <- function(x) dbeta(x, shape1 = 2, shape2 = 3) # Dist. alvo: X \sim Beta(2, g \leftarrow function(x) dnorm(x, 0.5, 0.25) # Dist. candidata: X \sim N(g \leftarrow function(x) dnorm(x, 0.5, 0.25)
 curve(g, add=TRUE, col=2)
 legend("topright", legend=c("Alvo", "Candidata"), lty=1, col=1:2, bty="n")
 # Algoritmo M-H | Amostrador Independent
# N <- 500; x2 <- numeric(N); x2[1] <- 0.5; k2 <- 0; for(i in 2:N) {
       y <- rorm(1, 0.5, 0.25) # Distribuição proposta
alpha <- min((f(y) * g(x2[i - 1])) / (f(x2[i - 1]) * g(y)), 1)
       u <- runif(1)
       if(u <= alpha) {
            x2[i] <- y
k2 <- k2 + 1
       } else {x2[i] <- x2[i - 1]}</pre>
                                      # Taxa de Aceitação
 plot(ecdf(x2))
 acf(x) # Funcão de Autocorrelação (Am. Ind.) curve(obeta(x, 2, 3), add = T, col = 2)
  Seja x=(x_1,\cdots,x_{10})=(2,2,1,1,5,4,4,3,1,2). Obter a amostra bootstrap de x.
 cumsum(prop.table(table(x)))
                                                       # Distribuição empírica acumulada
 Repare-se que sendo X - Poisson(0) tem probabilidade \# 0. Reamostrar a partir desta amostra um grande nº de x produz um boa estimativa de F_{xy} ass não uma boa estimativa de F_{xy} dado que as amostras boatstrap munca incluírão o 0. am x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x - x
 prop.table(table(am))
  cumsum(prop.table(table(am)))
plot(0:5, c(0, prop.table(table(amB))), type = "h") # Representa a dist. empirica points((0:5) + .1, dpois(0:5, 2), type = "h", col = 2) # Representa a dist. teórica
 # Intervalo de Confiança de Wald (Intervalo normal padrão de Bootstrap) [EXTRA]
                                                             \hat{\theta} \pm Z_{\alpha} \times \text{se}(\hat{\theta})
  (lower95.limit <- mean(R) - gnorm(0.975) * se.R)
 (upper95.limit <- mean(R) + qnorm(0.975) * se.R)
                           ---- Simulação de Eventos Discretos [3] | Simmer ----
  # Ahandono da Fila
 customer <- trajectory("Customer") %>%

... renege_in(tempo, out = trajectory("Reneging customer") %>% log_("I am off")) %>%
       ... renege_abort() # Se o recurso ficar Livre antes do tempo, o abandono deve ser cancelado
customer <- trajectory("Customer") %>%

# 0 cliente decide qual fila entrar - Regra do Exemplo: entrar na fila + curta
... select(c"counter1", "counter2"), policy = "shortest-queue") %>%
seize_selected() %>%
# Entrar na fila escolhida - Bloqueta-a
    release_selected() %>% # Libertar a fila escolhida - Já foi atendido
 # Horário de Funcionamento (Aberto: 8h às 24h (com ≠ nº de recursos) | Fechado: 24h às 8h)
 door_schedule <- schedule(timetable = c(8, 16, 24), values = c(Inf,2, 0), period = 24)
env %>% ... add resource("door", canacity = door schedule) %>% ...
 customer <- trajectory() ... %>% batch(n = Inf, timeout = 30) %>% separate() %>%
   * timeout: define um temporizador que "dispara" Lotes a cada x tempo, mesmo que o n não tenha sido preenchido
# Bifurcações na Trajetória (85% segue a trajetória 1)
customer <- trajectory() _ %>% branch(function() (runif(1) > 0.85) + 1, # Atenção ao >
                                                              continue = c(FALSE, FALSE).
                                                             trajectory("1"), trajectory("2"))
```